

Compte-rendu de la SAE : Régression

Yvan NEDELEC

Dawei ZHOU


Dans cette SAE Régression, nous avons comme objectif de créer un modèle statistique à partir d'un échantillon de 12796 prix de vente (appelé valeur foncière) et des variables donnant des informations concernant chaque logement qui se trouvent dans un fichier csv nommé "train.csv" et l'appliquer sur 2000 logements avec toutes les même données sauf le prix de vente qui sont eux dans un fichier csv nommé "test.csv" afin d'analyser la régressivité de ces variables avec la valeur foncière. Pour cela nous allons utiliser deux logiciels: premièrement Excel, afin d'analyser les deux échantillons et de visualiser le traitement nécessaire à apporter au fichier original afin que nous puissions construire un modèle représentatif de la population et puis R (Studio) afin d'automatiser le traitement de données, la création d'un modèle et d'un fichier csv final avec nos prédictions.

Pour commencer, nous avons téléchargé le fichier 'train.csv' et nous avons copié les valeurs sur un autre fichier Excel. En suite, nous avons filtré les données en enlevant les 10% des valeurs les plus basses et 10% des valeurs les plus hautes pour avoir des données qualitatives car nous avons remarqué qu'il y avait certaines données aberrantes notamment avec la valeur foncière qui des fois était de 100 euros ou même 1 euros et aussi des données qui sont tellement grandes qu'elles faussent nos prédictions.

Nous avons également enlevé les appartements dont la surface est supérieure à 200. N'ayant pas de logement de plus de 200m² dans le fichier test, ajouter des valeurs si hautes fausserait l'équation du modèle. Nous avons également pensé à enlever les logements qui ont en nombre de pièce 0 pièce mais nous nous sommes aperçus que dans le jeu de données 'test.csv', il y avait également des données qui ne contenaient pas de pièces principales, nous les avons donc laissé dans l'échantillon

Nous avons aussi pensé à créer deux modèles différents pour s'adapter au type de logement ayant aperçu que la valeur foncière des maisons surpassent largement celles des appartements sur Paris mais analysant plus précisément, l'effectif de ces maisons est tellement faible (moins de 1%) par rapport au nombre total de données dans les fichiers "train.csv" et "test.csv" qu'on a décider de ne pas les prendre en compte.

Nous avons commencé notre travail sur Excel en croisant la valeur foncière avec la surface des bâtiments. Nous avons donc appliqué les filtres exposés ci-dessus et nous avons obtenu ceci :



Nous avons ensuite décidé de prendre en compte les arrondissements dans nos calculs. Nous avons calculé la moyenne globale de la valeur foncière, et la moyenne de la valeur foncière par arrondissement. Et nous avons ajouté cette différence aux valeurs prédites. Cela permet de stabiliser le modèle et de prendre en compte les différences de prix par arrondissement.

Il est clair qu'en effet le prix des logements dans le 1er arrondissement ou dans le 16ème arrondissement n'est pas le même que dans le 18ème ou même le 20ème. Pour terminer, deux modèles ont retenu notre attention : le modèle linéaire et le modèle puissance car les deux ont un coefficient de détermination R^2 similaire.

Valeur.fonciere	Vfth Lin	Dif Lin carre	Vfth Pui	Dif Pui carre				Moy	Eqtype			
150000	998901,791	7,20634E+11	959088,7156	6,54625E+11		Somme carre Lin		484992,424	263621,769			
150000	492840,551	1,1754E+11	480434,188	1,09187E+11		2,03729E+14			n	Somme Vf	Moyenne Vf	Mod Arrond
150000	403310,255	64166085480	391563,8637	58353100225		Moy dif Lin	Paris 01		118	63504025,7	538169,709	53177,2857
150000	271898,151	14859159117	260669,7813	12247800502		1395,109013	Paris 02		154	76141482,1	494425,208	9432,7846
150000	461902,583	97283220985	450331,3066	90198893742		Somme carre Pui	Paris 03		215	119096552	553937,449	68945,0258
150000	477254,891	1,07096E+11	465494,9177	99537043068		2,03222E+14	Paris 04		161	89412727,1	555358,553	70366,1298
150000	322262,027	29674205899	310273,7771	25687683616		Moy dif Pui	Paris 05		296	153751628	519431,174	34438,7506
150000	379470,054	52656505727	367212,3575	47181208234		1393,372537	Paris 06		204	123072929	603298,672	118306,248
150000	198684,551	2370185466	185757,4432	1278594745			Paris 07		224	132720739	592503,299	107510,875
150000	239392,526	7991023690	225104,6547	5640709160			Paris 08		162	99891955	616617,006	131624,583
150000	246184,548	9251467320	231338,5588	6615961145			Paris 09		346	194327294	561639,578	76647,1541
150000	249048,427	9810590864	233587,4436	6986860731			Paris 10		587	283676128	483264,272	-1728,15176
150000	221089,126	5053663823	205628,1427	3094490257			Paris 11		897	419186533	467320,55	-17671,8741
150000	221089,126	5053663823	205628,1427	3094490257			Paris 12		653	300739199	460550,075	-24442,3485
150000	211124,555	3736211270	195663,5721	2085161820			Paris 13		497	216106049	434821,025	-50171,3988
150000	273199,751	15178178558	257738,7674	11607642001			Paris 14		576	263437044	457355,979	-27636,4446
150000	252603,795	10527538682	237142,8114	7593869585			Paris 15		1142	569669819	498835,218	13842,7947
150000	144664,824	28464103,52	128528,7665	461013866,2			Paris 16		706	452631436	641121,015	156128,591
150000	337120,175	35013960063	320984,1181	29235568627			Paris 17		896	443770746	495279,851	10287,4269
150000	131171,672	354505931,8	113490,5449	1332940315			Paris 18		1095	437077434	399157,474	-85834,9494
150000	125470,951	601674265,1	107789,8234	1781699013			Paris 19		599	242510059	404858,196	-80134,2279
150000	225148,695	5647326312	207467,5674	3302521308			Paris 20		703	281233707	400047,948	-84944,4761
150000	161134,501	123977116,5	143453,3739	42858312,71								

A la suite de cette comparaison effectuée sur Excel, nous avons décidé de retenir le modèle puissance car il possède le meilleur coefficient de corrélation.

a	0.877555773741695
b	9.68695631594362
covxy	0.232012481580755
header	chr [1:2] "id" "valeur.fonciere"
moyennes	484816.369721489
q01	Named num 150000
q09	Named num 1280788
r	0.851028034284553
SCR	221802830953528
sqrtr	0.92251180712474
varx	0.264384884155576
vary	0.281124272001601

Concernant la partie sur R(Studio), nous avons dû faire face à différents problèmes : tout d'abord, nous avons peiné à mettre les filtres des quartiles sur le Data Frame issu du fichier csv "train". Nous avons également eu du mal à faire une moyenne par arrondissement automatisée. Pour finir, nous avons eu des difficultés à faire le Data Frame de la table finale pour ensuite l'exporter en csv. Mais ces problèmes ont tous été résolus avec des recherches sur Internet.

Nous avons donc le coefficient R égal à 0.85 environ sur les données du fichier 'train' obtenu par une analyse sur R(Studio). En effet, le modèle puissance permet de mieux s'adapter à une large gamme de données, et s'adapte mieux aux valeurs extrêmes d'un jeu de données que le modèle linéaire. Avec certaines recherches, nous avons vu que le modèle puissance était très souvent utilisé dans l'approximation des valeurs foncières. Nous avons donc:

$$y = e(b) \cdot x^a$$

avec a = 0.8775557737417 et b = 9.6869563159436

Pour conclure, notre étude de régression a permis de mettre en lumière plusieurs aspects importants concernant la prédiction des valeurs foncières des logements. Tout d'abord, nous avons effectué un travail minutieux de prétraitement des données, en éliminant les valeurs aberrantes et en tenant compte des spécificités des logements, telles que la surface et l'arrondissement.

En utilisant Excel pour explorer nos données initiales, nous avons identifié des tendances significatives, notamment en croisant la valeur foncière avec la surface des bâtiments. Ensuite, nous avons affiné notre analyse en prenant en compte les différences de prix par arrondissement, ce qui a permis de stabiliser notre modèle.

Après avoir testé plusieurs modèles sur R, nous avons retenu le modèle puissance comme le plus approprié pour notre ensemble de données. Son coefficient de corrélation élevé de 0.85 sur les données du csv "train" démontre sa capacité à capturer les variations complexes des prix fonciers, y compris les valeurs extrêmes.

Enfin, en utilisant l'équation du modèle puissance, nous sommes en mesure de prédire les valeurs foncières avec précision pour de nouveaux logements, ce qui pourrait être d'une grande utilité pour les professionnels de l'immobilier, les investisseurs et les autorités municipales dans la prise de décisions éclairées concernant le marché immobilier.

Nous avons l'impression d'avoir fait un modèle qui ressemble au mieux aux valeurs réelles. Nous avons essayé beaucoup de choses afin de construire un modèle fiable et efficace, s'adaptant aussi bien aux valeurs extrêmes qu'aux valeurs normales.